

基于深度学习的电动车头盔检测系统设计

摘要：随着我国城市道路网络的建设与分布的日益优化，人们的出行方式得到了进一步拓展，由于电动自行车具有通勤便利性，在众多的出行方式中占据了很高的比例。为了降低交通管理工作强度，实现头盔佩戴自动化监管，亟需解决的问题是如何实现电动车头盔智能检测。本文以城市道路中电动车骑行人员视频为对象，进行了基于深度学习的电动车头盔佩戴检测研究，主要研究内容如下：(1) 建立电动车头盔视频数据集。对采集到的道路口监控视频进行“抽帧采样”得到原始数据集，并对原始数据集离线增强和在线增强得到自制电动车头盔佩戴检测数据集，进一步提高模型的泛化能力。(2) 在 YOLOv8n 目标检测网络中添加小目标检测层、替换上采样算子、添加 BiFormer 注意力机制以提升检测性能。电动车头盔检测是一个密集的、小目标较多的场景，因此添加小目标检测层以提高网络模型对小目标物体的检测能力。将上采样算子 CARAFE 替换原有的默认上采样算子，以提高模型性能。BiFormer 是一种新的通用视觉变换器，在性能和计算效率方面非常出色，本文在小目标检测层部分加入这种注意力机制，以提高模型性能。大量实验结果表明，与原算法相比本文算法准确率提升了约 2%，达到了 96.2%

关键词：深度学习、YOLOv8、电动车头盔检测、CARAFE、BiFormer

0 引言

在学术领域，胡光喆提出了一种基于多尺度特征融合和注意力机制的优化算法，针对此优化方法带来的模型复杂度增加问题，提出用 Ghost 模型压缩模块降低模型复杂度，提高算法推理速^[1]。徐栋在 YOLOv5 的基础上使用 Ghost Bottleneck 模块替换 YOLOv5 中的卷积模块以减少参数量，同时在主干网络增加注意力机制以提升检测精度，最后引入 CIOU 损失函数提高模型训练过程的收敛速度^[2]。蒋润康将 YOLOv5 网络中的部分 CSPDarknet53 特征提取网络更换成 Transformer 网络，使用加权双向特征金字塔网络(BiFPN)模块替换了 YOLOv5 原本使用的特征金字塔网络，并加入 anchor-K-Means 聚类算法^[3]。余泽研究了一种基于改进 Retina Net 模型的头盔佩戴检测方法，具体是使用可变形卷积替换普通卷积^[4]。彭名扬等人使用 YOLOv5 算法直接应用于电动二轮车骑行人员的佩戴检测，取得了良好的效果^[5]。王新等人针对原 SSD 网络参数多的问题，提出了一种基于 SSD 网络 EfficientNetV2-SSD 算法，改算法使用改进后的轻量级网络 EfficientNetV2 替换 SSD 中的特征提取网络，减少网络参数，提升网络检测速度^[6]。李玄锋等人提出了一种基于 YOLOv5 改进的卷积神经网络模型的电动车头盔佩戴检测识别系统，通过对骑行人员佩戴头盔情况进行智能识别，并部署于嵌入式平台 Jetson nano 上^[7]。丁梦迪等人是在 YOLOv3 算法主网络后增加残差结构，进而提高了位置与类别的识别精度，同时设计了 GUI 应用界面，便于应用测试^[8]。吕佳俊实现了一种基于 Center Net 的电瓶车骑行人员检测算法，与其他人不同的是，他基于 PyQt 设计了报警系统^[9]。庄建军等人提出一种基于改进的 YOLOv5m 模型的头盔与车牌检测方法，该方法不仅能识别骑行人员头盔佩戴情况，还能识别出电动车的车牌号，进一步推进了电动车头盔佩戴检测领域的研究^[10]。

1 电动车头盔检测算法

YOLOv8 目标检测算法是优秀的一阶段检测算法，既有高的检测速度，又可达到良好的检测效果。因此本文选用 YOLOv8 作为道路电动车头盔佩戴检测算法，同时分析 YOLOv8 算法适用场景场景以及特点，并基于此对 YOLOv8 算法进行调整优化，以更加适用于本文中 helemt、No-helemt 两类目标的检测。

1.1 YOLOv8 目标检测算法框架

YOLOv8n 的网络结构主要包括三个部分，分别是 Backbone 部分、Neck 部分以及 Head 部分，Backbone 部分为主干特征提取网络，用来对输入的图像行特征信息提取，Neck 部分

为 FPN 和 PAN 结构，主要作用是更好的融合、提取 Backbone 主干网络输出的不同尺度特征图，进而提升网络的性能，Head 预测部分主要根据 Neck 部分的特征图信息对图像的种类和位置进行检测。图 1 为 YOLOv8n 整体网络结构图。




图 1 YOLOv8n 整体网络结构图

1.2 YOLOV8 算法优化

(1) 添加小目标检测层

为了实现上述微小目标同样可以达到较好的检测效果，YOLOv8n 模型上通过 P2 层特征引出了新的检测层，结构如图 2 所示。P2 层检测层分辨率为 160×160 像素，相当于在主干网络中只进行了 2 次下采样操作，含有目标更为丰富的底层特征信息。颈部网络中自上而下和自下而上得到的两个 P2 层特征与主干网络中的同尺度特征通过 Concat 形式进行特征融合，输出的特征为 3 个输入特征的融合结果，这样使得 P2 层检测层应对小目标时，能够快速有效的检测。P2 层检测层加上原始的 3 个检测层，可以有效缓解尺度方差所带来的负面影响。增加的检测层是针对底层特征的，是通过低水平、高分辨率的特征图生成的，该检测层对微小目标更加敏感。




图 2 添加小目标检测层后的结构图

(2) 替换上采样算子为 CARAFE

上采样运算是指在某一特定区域内，将各区域的上采样核心与相应区域内的像素进行点乘，即所谓的特征重构。上采样运算 CARAFE 在重构时接收到的信号野大，能够依据信号特性引导重构，且整体运算更轻。具体来说，首先利用输入特征图来预测上采样核，每个位置的上采样核是不同的，然后基于预测的上采样核来进行特征重组。在不同的任务中，CARAFE 都取得了明显的提升，同时仅带来很小的额外参数和计算量。

(3) 添加 BiFormer 注意力机制模块

BRA 模块如图 3 所示，BRA 模块的核心思想是在粗区域级别过滤掉最不相关的键值对。它是通过首先构建和修剪区域级有向图，然后在路由区域的联合中应用细粒度的 token-to-token 注意力来实现的。值得一提的是，该模块的计算复杂度可压缩到很低。




图 3 BRA 模块

如图 4 所示，基于 BRA 模块构建了一个金字塔结构的视觉 Transformer——BiFormer，它在四种流行的视觉任务、图像分类、目标检测、实例分割和语义分割方面均表现出卓越的性能。




图 4 BiFormer 模块

2 实验结果与分析

2.1 实验环境与数据集

如表 1 所示，本文选用的实验平台本地操作系统为 Windows10，操作软件为 Pycharm，使用 AutoDL 云端服务器操作系统为 Python3.8(ubuntu20.04)、型号为：12 vCPU Intel(R) Xeon(R) Platinum 8255C CPU @ 2.50GHz、GPU 为显存 32GB 的 V100-SXM2-32GB(32GB) * 1。通过 Pytorch 软件实现了对目标检测模型的建立、训练以及对实验结果的分析。

表 1 实验环境

配置名称	环境配置
镜像	PyTorch 1.11.0 Python3.8(ubuntu20.04)Cuda 11.3
GPU	V100-SXM2-32GB(32GB) * 1
CPU	12 vCPU Intel(R) Xeon(R) Platinum 8255C CPU @ 2.50GHz
内存	43GB
硬盘	系统盘:25 GB 数据盘:免费:50GB SSD 付费:0GB

目前道路电动车头盔佩戴检测方面没有公开的数据集，为构建电动车头盔佩戴检测数据集，本文分别在不同地点、不同光照强度、不同天气、不同时段等多种场景下进行数据采集，然后对采集的原始图像数据集进行离线增强，从而构建一套高质量电动车头盔数据集，包含图像 7286 张。

2.2 评价指标

模型评估作为机器学习领域一项不可分割的部分，却常常被大家忽略，其实在机器学习领域中重要的不仅仅是模型结构和参数量，对模型的评估也是至关重要的，只有选择那些与应用场景匹配的评估方法才能更好的解决实际问题。一般来说，单一评分标准无法完全评估一个机器学习模型，只用好坏去评估某个模型是一种欠妥的评估方式。常用的有查准率（Precision）和召回率（Recall）、置信度、AP 和 mAP。

(1)查准率（Precision）和召回率（Recall）

Precision 和 Recall 的计算需要用到 TP、FP、FN 这三个概念。T 代表 True；F 代表 False；P 代表 Positive；N 代表 Negative。T 和 F 表示这个样品的归类有没有准确。P 和 N 表示这个样品的预期结果是正面的，还是负面的。

计算查准率（Precision）的公式 1:

$$Precision = \frac{TP}{TP+FP} \quad (1)$$

Precision 是指被分类器认定为“正类”的那一部分，在全部分类器认定为“正类”的那一部分中所占有的比重。TP 是一个示例，在该示例中，分类器确认为正值并且的确是正值，FP 是一个示例，在该示例中，分类器确认为正值，但是并不是正值。

计算召回率（Recall）的公式 2:

$$Recall = \frac{TP}{TP+FN} \quad (2)$$

其中，Recall 是指被分类器视为正类，并且的确是正类的部分在全部的确是正类中的比重，TP 是被分类器视为正类，且是正类，FN 是被分类器视为负类，但不是负类。

(2)置信度

在目标检测算法中，有一个很关键的概念就是置信度，置信度高，那么，所得到的结果就与真实的情形十分吻合，置信度低，那么，就会出现大量的假检测。

(3)AP 和 mAP

AP（Average Precision）指的是单一分类的准确率，而 mAP 则指的是全部分类的准确率。实际上，AP 就是通过各种精密度和密度的结合，绘制出的一条曲线。在选取不同的置信程度时，会得到不同的优先级和优先级，选取置信程度足够高时，会得到很高的优先级和优先级。这时优先级和优先级就可以在图像上划一条直线，这个直线下面的区域就是某一类的优先级。mAP 就是所有的类的 AP 值求平均，公式 3:

$$mAP = \frac{\sum_{i=1}^n AP_i}{n} \quad (3)$$

mAP@0.5 和 mAP@0.5:0.95 是衡量模型直接使用的指标。mAP@0.5 指的是在 IOU 为 0.5 的情况下，对每个类中的图像进行 AP 计数，并对每个类进行平均值。0.5:0.95 代表了在各种 IOU 门限下（0.5~0.95，步骤 0.05）的平均 mAP。

(4) IOU

IOU 是一种用于物体探测的新方法，其目的是通过计算“预测边界”和“实际边界”之间的重叠比率，也就是两种边界的交叉与交叉比率。最好的结果是完美的交迭，也就是比率是 1。

IOU 计算公式 4:

$$IOU = \frac{|A \cap B|}{|A \cup B|} \quad (4)$$

2.3 模型训练

在训练前对其 YOLOv8n 模型超参数进行调整, 初始学习率均设置为 0.01, 终止学习率 0.01, 每次送入网络训练的样本数量为 16, 训练轮数为 100 轮, 训练图像尺寸设置为 640×640, 具体实验参数如表 2 所示。

表 2 训练参数

参数名称	参数设置
输入图像维度	640 × 640 × 3
训练次数	100
批次大小	16
初始学习率	0.01

2.4 消融实验

消融实验通过控制变量法验证本文提出的小目标检测层(P2)、上采样算子 CARAFE, BiFormer 注意力机制、三种模块不同组合下的模型性能, 从而分析出性能最好的模块组合。具体消融实验对比如表 3 所示。

表 3 消融实验对比表

模型	P/%	R/%	mAP@0.5/%	GFLOPs
Baseline	93.3	88.6	94.2	8.7
+P2	93.5	88.8	94.4	8.9
+CARAFE	93.9	89.2	94.4	9.0
+BiFormer	94.2	89.4	94.8	9.2
+ P2+ CARAFE	94.4	89.7	95.2	9.5
+ P2+BiFormer	94.6	90.1	95.6	9.9
+ CARAFE+BiFormer	95.0	90.2	96.0	10.0
+P2+CARAFE+BiFormer	95.2	90.4	96.2	10.1

从上述消融实验结果得出以下结论:

(1) 在基准网络的基础上分别单独加入小目标检测层、上采样算子 CARAFE 和 BiFormer 注意力模块, 能够有效提升模型的平均精确率, 精确率和召回率, 但是其每秒 10 亿次的浮点运算数随之增加, 这也证明添加小目标检测层、上采样算子 CARAFE 和 BiFormer 注意力模块能够有效提升模型精确率, 但是与此同时增加了模型复杂度。由于本文选择的基线网络 YOLOv8 模型运算速度足够快, 而检测精度不够优秀, 加入小目标检测层、上采样算子 CARAFE 和 BiFormer 注意力模块带来的运算速度的下降也能接受。

(2) P2 与 CARAFE 组合时, 模型平均精确率提升了 1 个百分点, 和 BiFormer 注意力模块组合时, 平均精确率提升了 1.4 个百分点, CARAFE 与 BiFormer 组合时, 平均精确率提升了 1.8 个百分点, 同时每秒 10 亿次的浮点运算数轻微向上浮动, 和基准网络基本一致。

(3) 同时引入小目标检测层、上采样算子 CARAFE 以及 BiFormer 注意力模块, 模型的精确率、召回率和平均精确率都有不错的提升, 其平均精确率比基准网络高出了 2 个百分点, 进一步验证了优化调整网络的有效性。

3 结论

根据道路骑行人员电动车头盔佩戴检测存在的实时性检测效果差, 小目标识别准确率低等难点, 进行针对性分析及研究。完成了工作: 自制电动车头盔佩戴检测数据集; 优化 YOLOv8n 目标检测算法。但仍存在一些不足之处, 可以考虑加上人脸识别功能, 人脸识别功能是一个非常有用的补充功能, 用于监控数据集中的违规信息人员的信息确认。例如, 当采集流程中出现任何电动车骑行者不佩戴安全头盔时, 该功能可以记录这些人的图片, 并进行人脸识别, 为交警人员提供处罚依据, 进一步提高安全头盔检测系统的综合性能力。

参考文献

- [1]. 胡光喆. 基于深度学习的道路安全头盔佩戴检测算法研究[D]. 中国矿业大学, 2022. DOI:10.27623/d.cnki.gzkyu.2022.000199.
- [2]. 徐栋. 基于深度学习的电动车头盔佩戴检测系统的设计与实现[D]. 南京邮电大学, 2022. DOI:10.27251/d.cnki.gnjdc.2022.000244.
- [3]. 蒋润康. 基于深度学习的电动车骑行人员头盔佩戴检测系统[D]. 宁夏大学, 2022. DOI:10.27257/d.cnki.gnxhc.2022.001825.
- [4]. 余泽. 基于深度学习的骑行人员头盔佩戴检测技术研究[D]. 浙江工商大学, 2022. DOI:10.27462/d.cnki.ghzhc.2022.000637.
- [5]. 彭名杨, 陈亚军. 基于 YOLOv5 的安全头盔佩戴检测方法研究[J]. 太原师范学院学报(自然科学版), 2022, 21(04): 64-69.
- [6]. 王新, 冯艺楠. 基于改进 SSD 的骑行人员佩戴头盔检测[J]. 电子测量技术, 2022, 45(21): 90-97. DOI:10.19651/j.cnki.emt.2209761.
- [7]. 李玄锋, 夏毅, 黄越, 袁荣骏, 郁佳佳. 基于改进 YOLOv5 的智慧交通电动车头盔佩戴识别系统[J]. 信息技术与信息化, 2022(09): 203-206.
- [8]. 丁梦迪, 李元熙. 基于 YOLOv3 的骑行人员头盔佩戴识别系统设计与实现[J]. 中国新通信, 2021, 23(13): 44-45.
- [9]. 吕佳俊. 基于深度学习的安全头盔实时检测与报警系统的设计与实现[D]. 西南大学, 2021. DOI:10.27684/d.cnki.gxndx.2021.003171.
- [10]. 庄建军, 叶振兴. 基于改进的 YOLOv5m 电动车骑行者头盔与车牌检测方法[J/OL]. 南京信息工程大学学报(自然科学版): 1-13 [2023-05-26]. <http://kns.cnki.net/kcms/detail/32.1801.N.20230105.0830.001.html>